

< Hola, somos Castor >



IA Generativa

De los modelos a la creación de
soluciones inteligentes



Consultoria > Diseño > Desarrollo



Bienvenida e Introducción

- Presentación del instructor.
- Presentación del curso.
- Un Vistazo a la Evolución de la IA
- Tipos Principales de Modelos Generativos
- Conceptos Fundamentales
- Consideraciones Éticas Básicas
- Configuración del Entorno
- Primera Interacción: Usando una API
- Ejercicios Prácticos de Prompting Básico
- Experimentar con Parámetros Básicos
- Conclusiones de la Clase y Próximos Pasos



✓ Presentación del instructor




Edwin Trujillo Betancur


- Ingeniero de sistemas
- Especializado en gerencia de proyectos
- Apasionado del desarrollo, la agilidad y la IA Generativa.
- Con más de 37 años de experiencia en temas tecnológicos.
- Profesor de catedra en Cedesistemas, Escuela de Ingeniería de Antioquia, Tecnológico de Antioquia, EAFI
- Trabajo actual: Líder del laboratorio de investigación de GenIA y Agentes de Castor evolución digital

✓ Objetivo de este curso

Lograr que los alumnos comprendan los fundamentos de la IA Generativa, dominen herramientas clave y sean capaces de desarrollar una solución básica aplicando los conceptos de modelos, prompt engineering y agentes.



✓ Objetivos Clase 01




- Definir IA Generativa y distinguirla de la IA tradicional.
- Identificar los principales tipos de modelos generativos.
- Comprender intuitivamente los conceptos clave: LLM, prompt, token, embedding, parámetro.
- Realizar las primeras interacciones prácticas con un modelo de lenguaje.
- Introducir brevemente las consideraciones éticas.


✓ IA Tradicional (o IA Clásica)

Se refiere a los enfoques anteriores de IA. Su objetivo principal es analizar datos que ya existen para comprenderlos o hacer predicciones sobre ellos.

- Sistemas Expertos
- Machine Learning
 - Clasificación
 - Predicción
- Fundamentalmente, trabaja con la información disponible, no crea contenido radicalmente nuevo por sí misma. Su acción principal es entender o predecir.



✓ El Salto hacia la IA Generativa



Describe los factores que permitieron el desarrollo reciente y explosivo de la IA capaz de crear.

- Impulsores Clave:
 - Big Data (Datos Masivos).
 - Potencia Computacional (GPUs).
 - Nuevas Arquitecturas (Transformers).

✓ IA Generativa (GenIA)

- Define este subcampo específico y más reciente de la IA.
- Es la rama de la IA enfocada en crear contenido nuevo y original.
- Puede generar diversos tipos de contenido (texto coherente, imágenes a partir de descripciones, código funcional, música, etc.) que se asemejan a lo que un humano podría crear.
- Aprende patrones, estilos y estructuras de los datos masivos con los que se entrena, y luego usa ese conocimiento para generar nuevas muestras.
- Su acción principal es crear o generar, yendo más allá del simple análisis o predicción de la IA tradicional.







Tipos Principales de Modelos Generativos

✓ Modelos de Lenguaje Grandes (LLMs)

- Son modelos entrenados con enormes volúmenes de texto. Su función es entender y producir lenguaje humano. Son el motor detrás de chatbots conocidos (ChatGPT, Gemini, etc.). Hay muchos otros, incluyendo opciones de código abierto (open-source).
- Se basan principalmente en la arquitectura "Transformer", una innovación técnica crucial para su éxito.
- Pueden realizar una amplia variedad de tareas lingüísticas como responder preguntas, traducir idiomas, resumir textos largos, ayudar a escribir código, redactar emails, inventar historias, y mucho más.
- Piensa en ellos como un "cerebro" digital especializado en lenguaje, muy leído y capaz de adaptarse a diferentes tareas de escritura o conversación.



✓ Modelos de Difusión (para Imágenes)



- Son modelos que generan imágenes a partir de descripciones textuales (prompts).
- Empiezan con "ruido" (una imagen aleatoria) y gradualmente la refinan, guiados por el prompt, hasta formar la imagen deseada.
- Ejemplos Populares: Stable Diffusion (open-source), Midjourney (servicio), DALL-E (OpenAI).
- Ejemplo: crear una imagen de un astronauta montando a caballo en la luna, estilo DC Comic

✓ Otros Modelos

- Generación de música: (ej. MusicLM, Suno).
- Generación de código (ej. GitHub Copilot, CodeGPT, Cursor, Bolt, V.0),
- Modelos multimodales (entienden y generan texto e imágenes, videos, audios, como Gemini, GPT, Claude).






Conceptos Fundamentales

✓ Prompt



- La instrucción, pregunta o texto de entrada que le damos al modelo.
- Es la clave para guiar la generación.
- La calidad del prompt afecta directamente la calidad de la respuesta.
- Ejemplos:
 - "Escribe un poema sobre la lluvia",
 - "¿Cuál es la capital de Francia?",
 - "Resume el siguiente texto: [...]".

Diseñando un Prompt Eficaz para Inteligencia Artificial



✓ Otros elementos del prompt

- **Completion / Response:** La salida generada por el modelo en respuesta al prompt.
- **Temperatura:** Controla la "creatividad" vs. la "predictibilidad".
 - 0.0 - 0.3: Muy determinista, bueno para respuestas basadas en hechos.
 - 0.7 - 1.0+: Más creativo, diverso, a veces inesperado. Bueno para escritura creativa.
- **Tokens:** Las unidades básicas en las que los modelos procesan el texto. No son exactamente palabras, pueden ser partes de palabras, palabras enteras o signos de puntuación. 1000 tokens son aproximadamente 700 palabras.



✓ Top P (Nucleus Sampling):



- Es un método para controlar la aleatoriedad de la respuesta, alternativo o complementario al parámetro temperature.
- En lugar de considerar todas las posibles palabras siguientes, el modelo considera solo el conjunto más pequeño de palabras cuya probabilidad acumulada suma el valor top_p (ej. top_p=0.9 considera las palabras más probables que suman el 90% de la probabilidad total). Luego, elige aleatoriamente dentro de ese conjunto reducido (el "núcleo").
- Un top_p bajo (ej. 0.1) hace que el modelo sea muy conservador y determinista, eligiendo solo entre las opciones más obvias.
- Un top_p alto (ej. 0.9 o 1.0) permite más diversidad y creatividad, considerando también opciones menos probables pero aún plausibles.
- Utilidad: Ajustar el nivel de "sorpresa" o creatividad del texto generado, manteniendo la coherencia.

✓ Tamaño de Salida (o max_tokens / maximum length)

- Define la longitud máxima de la respuesta que generará el modelo, medida en tokens.
- Sirve para limitar la extensión de la salida, evitando respuestas excesivamente largas o cortas.
- El modelo dejará de generar una vez alcance este límite, incluso si no ha completado una frase o idea.
- Permite controlar costos (muchas APIs cobran por token generado) y asegurar que la respuesta tenga una longitud adecuada para el uso deseado.



✓ Stop Sequence (Secuencia de Parada)



- Es una cadena de texto específica (o una lista de cadenas) que le indicas al modelo. Si el modelo genera exactamente esta secuencia de texto, detendrá la generación inmediatamente en ese punto.
- La generación se corta justo antes de incluir la secuencia de parada en la respuesta final. La secuencia de parada en sí no aparece en la salida.
- Muy útil para controlar el formato de salida (ej. detenerse después de un salto de línea específico `\n\n` o un marcador como FIN), o para evitar que el modelo siga generando contenido no deseado después de haber completado la tarea.

✓ Parámetros

Los valores internos del modelo que se ajustan durante el entrenamiento. Los modelos grandes tienen miles de millones de parámetros. Más parámetros generalmente (no siempre) implican mayor capacidad, pero también mayor coste computacional. No confundir con los parámetros que ajustamos al usar el modelo





Consideraciones Éticas Básicas

Sesgos: Los modelos aprenden de datos del mundo real, que contienen sesgos sociales, históricos, etc. Pueden perpetuar o incluso amplificar estos sesgos.

Desinformación y Mal uso: Facilidad para generar texto o imágenes falsas (deepfakes, noticias falsas) de forma convincente.

Propiedad Intelectual: ¿De quién es el contenido generado? ¿Se infringen derechos de autor del material de entrenamiento? (Debate abierto).

Impacto Laboral: Potencial de automatizar tareas realizadas por humanos.

Importancia del Uso Responsable: Necesidad de ser críticos con los resultados y conscientes de las implicaciones.




Preguntas





Práctica



Organizaciones que Valoramos



Hemos sido aliados en la creación de más de 200 productos o servicios digitales



Hemos acompañado más de 300 iniciativas





Castor

Evolución Digital