

< Hola, somos Castor >



IA Generativa

De los modelos a la creación de
soluciones inteligentes




Consultoria > Diseño > Desarrollo

✓ Recapitulación Clase 1

- Entender los diferentes parámetros de una IA
- Entender la estructura de un prompt
- Uso de groq en un programa básico



✓ Objetivos Clase 02




- Identificar las APIs clave (OpenAI, Google Gemini, Hugging Face) para acceder a modelos de IA Generativa.
- Comprender la función y beneficios de usar frameworks como LangChain para orquestar y simplificar el desarrollo.
- Aprender a configurar y usar estos frameworks en Python para interactuar con LLMs.
- Construir la primera "Chain" (cadena) simple, conectando un prompt template con un LLM.
- Introducir conceptualmente la utilidad de los embeddings y las bases de datos vectoriales.


✓ ¿Por qué APIs?

Acceder a modelos potentísimos sin necesidad de la infraestructura masiva para entrenarlos o alojarlos nosotros mismos. Pagamos por uso.

- **OpenAI API:** Una de las más populares y pioneras. Conocida por los modelos GPT. Precios basados en tokens de entrada y salida. Chat Completions, Embeddings.
- **Google AI (Gemini API):** con fuerte énfasis en capacidades multimodales (texto, imagen, audio, video). Suele tener una capa gratuita generosa.
- **Hugging Face:** Más que una API, es una plataforma y comunidad enorme centrada en el Machine Learning. Acceso a una vasta colección de modelos pre-entrenados, muchos open-source.



✓ ¿Qué son LangChain y LlamaIndex?




Usar las APIs directamente está bien para empezar, pero al crear aplicaciones reales, el código se vuelve complejo rápidamente.


- **Frameworks** : Son bibliotecas de Python (y otros lenguajes) diseñadas para simplificar y estandarizar la creación de aplicaciones que utilizan LLMs.
- **Abstracción**: Proporcionan una interfaz común para interactuar con diferentes proveedores de LLMs (OpenAI, Google, Hugging Face, modelos locales). Escribes código similar independientemente del modelo de fondo.
- **Orquestación**: Ayudan a definir y ejecutar flujos de trabajo (secuencias de pasos) que involucran LLMs y otros componentes.

✓ Componentes Clave de los frameworks

- **LLM Wrappers:** Interfaces estandarizadas para llamar a diferentes modelos.
- **Prompt Templates:** Plantillas para crear prompts de forma dinámica y segura.
- **Output Parsers:** Herramientas para convertir la respuesta textual del LLM en formatos más útiles.
- **Chains (Cadenas):** La forma de conectar estos componentes en secuencia. Un input pasa por un componente, su output va al siguiente, y así sucesivamente. ¡El corazón de la orquestación!




✓ LangChain vs. LlamaIndex



- Ambos son excelentes.
- Históricamente, LangChain tenía un enfoque más amplio en orquestación general y agentes, mientras LlamaIndex se especializaba fuertemente en RAG (indexación y recuperación de datos).
- Hoy en día, sus funcionalidades se solapan bastante.

✓ Ventajas Clave de Usar Frameworks

- **Desarrollo Acelerado:** Menos código repetitivo. Componentes reutilizables.
- **Modularidad:** Fácil cambiar un componente (ej. probar un LLM diferente) sin reescribir todo.
- **Estandarización:** Código más fácil de leer, mantener y colaborar.
- **Acceso a Patrones Complejos:** Implementaciones listas para usar de técnicas como Chains, RAG y Agentes.
- **Comunidad Activa:** Muchos ejemplos, tutoriales e integraciones con otras herramientas.






Tipos Principales de Modelos Generativos

✓ Modelos de Lenguaje Grandes (LLMs)

- Son modelos entrenados con enormes volúmenes de texto. Su función es entender y producir lenguaje humano. Son el motor detrás de chatbots conocidos (ChatGPT, Gemini, etc.). Hay muchos otros, incluyendo opciones de código abierto (open-source).
- Se basan principalmente en la arquitectura "Transformer", una innovación técnica crucial para su éxito.
- Pueden realizar una amplia variedad de tareas lingüísticas como responder preguntas, traducir idiomas, resumir textos largos, ayudar a escribir código, redactar emails, inventar historias, y mucho más.
- Piensa en ellos como un "cerebro" digital especializado en lenguaje, muy leído y capaz de adaptarse a diferentes tareas de escritura o conversación.



✓ Modelos de Difusión (para Imágenes)



- Son modelos que generan imágenes a partir de descripciones textuales (prompts).
- Empiezan con "ruido" (una imagen aleatoria) y gradualmente la refinan, guiados por el prompt, hasta formar la imagen deseada.
- Ejemplos Populares: Stable Diffusion (open-source), Midjourney (servicio), DALL-E (OpenAI).
- Ejemplo: crear una imagen de un astronauta montando a caballo en la luna, estilo DC Comic

✓ Introducción a Embeddings y Bases de Datos Vectoriales

- Embeddings: Son representaciones numéricas (vectores) del significado del texto.
- Los LLMs son geniales, pero:
 - No conocen información específica y privada (tus documentos, tus emails, tu base de datos).
 - Tienen una ventana de contexto limitada.
- La Solución: Búsqueda Semántica.



✓ Base de Datos Vectorial (Vector Store)



- Es un tipo especial de base de datos optimizada para almacenar estos vectores de embeddings y realizar búsquedas de similitud (vecinos más cercanos) de manera muy eficiente.
- Imagina un catálogo gigante donde cada libro (fragmento de texto) tiene una coordenada basada en su contenido semántico. Cuando preguntas por un tema, la base de datos encuentra rápidamente los libros en esa "zona" del catálogo.
- Ejemplos: ChromaDB, FAISS (librería), Pinecone, Weaviate, Postgres, Supabase.




Preguntas





Práctica





Proxima Clase

- RAG Retrieval-Augmented Generation
- Agentes
- Recomendado ver los siguientes videos:
 - <https://www.youtube.com/watch?v=zoWgOUQQ Luk&t=2s>
 - <https://www.youtube.com/watch?v=Xh1Jv33RIKw>
- Crear una cuenta en <https://supabase.com/>

Organizaciones que Valoramos



Hemos sido aliados en la creación de más de 200 productos o servicios digitales



Hemos acompañado más de 300 iniciativas





Castor

Evolución Digital